

Introdução à Inteligência Artificial

- Abordagens de IA e tecnologias
- IA simbólica
- Aprendizado de Máquina
- Exemplos



Imagem: pixabay.com

IA?

- Ciência e Engenharia que estuda modelos para **construir máquinas/programas** que **atuem/comportem-se** de forma **inteligente/racional** na solução e acompanhamento de tarefas/problemas.

IA?

- Conjunto coletivo/cooperativo de sistemas capazes de receber entradas/sinais do ambiente, **interpretar e aprender** a partir desses sinais, e **exibir como consequência comportamentos e ações** flexíveis capazes de ajudar na solução de tarefas/problemas.

IA?

- **Tarefas complexas** e que exigem **criatividade** são mais **difíceis e custosas** de modelar (i.e. construir máquinas e programas que atuem racionalmente), mas...

IA?

- Tarefas complexas e que exigem criatividade são mais difíceis e custosas de modelar (i.e. construir máquinas e programas que atuem racionalmente), **mas tarefas repetitivas, previsíveis**, e com número de respostas limitado **são fáceis** de se modelar por IA.

Paradigmas de IA

conhecimento em intenção (regras)

Sistemas
Nebulosos
(fuzzy)

Redes
Bayesianas

Sistemas de PLN

Sistemas
Especialistas

Robôs

numérico

Algoritmos
genéticos

Sistemas
baseado
em casos

simbólico

Sistemas de
Aprendizagem
simbólica indutiva

Sistemas baseados em
Redes Neurais

conhecimento em extensão (exemplos)

Paradigmas de IA

- Em **IA simbólica** (busca, lógicas, representação de conhecimento) os **modelos** (determinísticos ou não determinísticos) são construídos para tomar decisões pré-estabelecidas.

Paradigmas de IA

- Em **IA simbólica** (exemplo)
 - Controle difuso de ABS

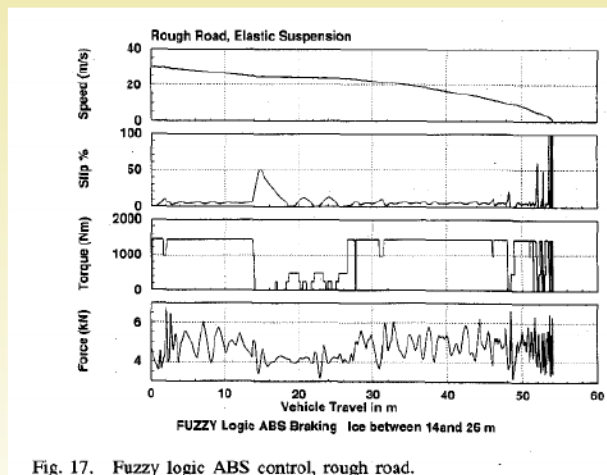


Fig. 17. Fuzzy logic ABS control, rough road.

A. Fuzzy Logic Rules

1. RULE DRY1;
IF DRY IS TRUE AND;
GLPRED IS NOT VLARGE;
THEN DGL IS LARGE;
RULE.1;
2. RULE DRY2;
IF GLISS IS LARGE AND;
DRY IS TRUE AND;
COUPLE IS LARGE;
THEN DGL IS MEDIUM;
RULE.2;
3. RULE DRY3;
IF GLISS IS SMALL AND;
DRY IS TRUE AND;
COUPLE IS LARGE AND;
GLPRED IS NOT VLARGE;
THEN DGL IS LARGE;
RULE.3;
4. RULE DRY4;
IF GLISS IS MEDIUM AND;
DRY IS TRUE AND;
GLPRED IS NOT VLARGE AND;
COUPLE IS LARGE;
THEN DGL IS LARGE;
RULE.4;
5. RULE ICE7;
IF ICE IS TRUE AND;
GLISS IS ZS AND;
COUPLE IS ZS;
THEN DGL IS ZS;
RULE.7;
6. RULE ICES;
IF GLISS IS ZERO AND;
ICE IS TRUE;
THEN DGL IS SMALL;
RULE.5;
7. RULE ICES;
IF GLISS IS SMALL AND;
ICE IS TRUE;
THEN DGL IS ZERO;
RULE.8;
8. RULE BLOCKAGE;
IF GLISS IS VLARGE AND;
GLPRED IS VLARGE;
THEN DGL IS ZERO;
RULE.9;
9. RULE WET10;
IF WET IS TRUE AND;
GLISS IS ZS AND;
GLPRED IS NOT LARGE;
THEN DGL IS SMALL;
RULE.10;
10. RULE WET11;
IF WET IS TRUE AND;
GLISS IS SMALL;
THEN DGL IS ZS;
RULE.11;
11. RULE WET12;
IF WET IS TRUE AND;
GLISS IS ZERO AND;
GLPRED IS NOT LARGE;
THEN DGL IS SMALL;
RULE.12.

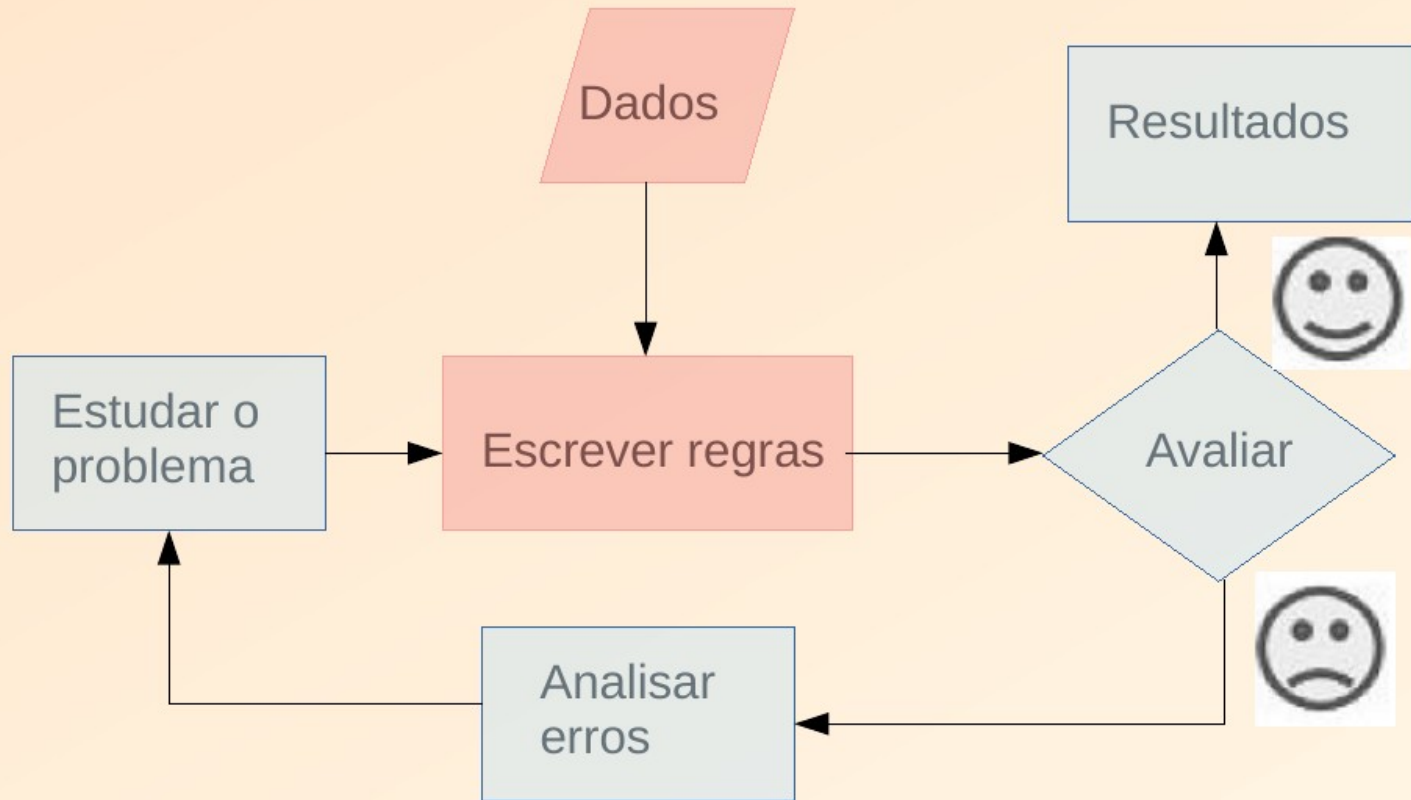
Mauer, A Fuzzy Logic Controller for an ABS Braking System, IEEE Transactions on Fuzzy Systems, 3(4), 1995.

Paradigmas de IA

- Em **Aprendizado de Máquina** são estudadas técnicas para **aproximar modelos** a partir de dados e/ou experiências.

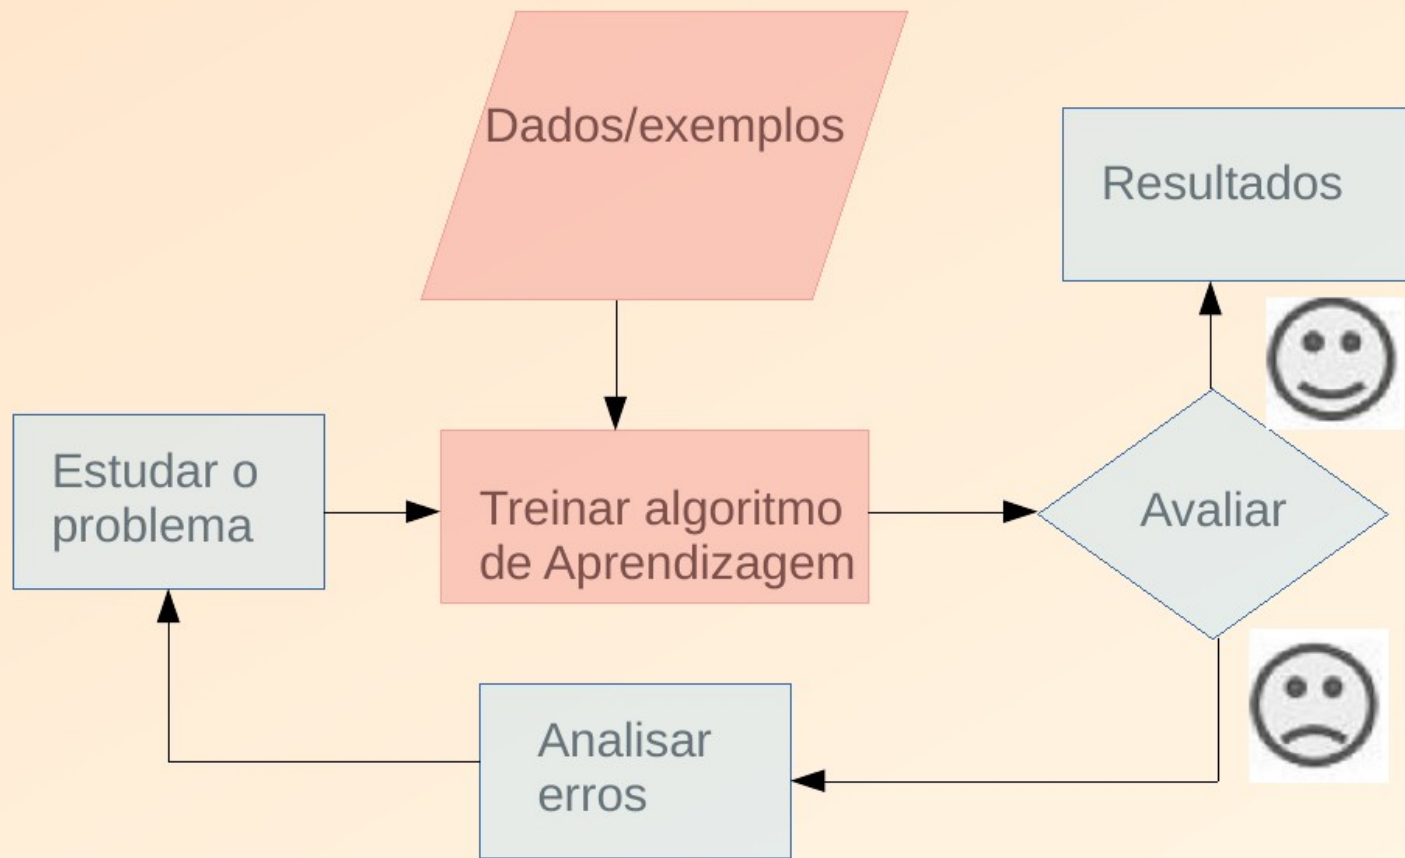
Exemplo: prog. tradicional

- Problema:** Escrever um programa que filtre e-mails “spam” no servidor.



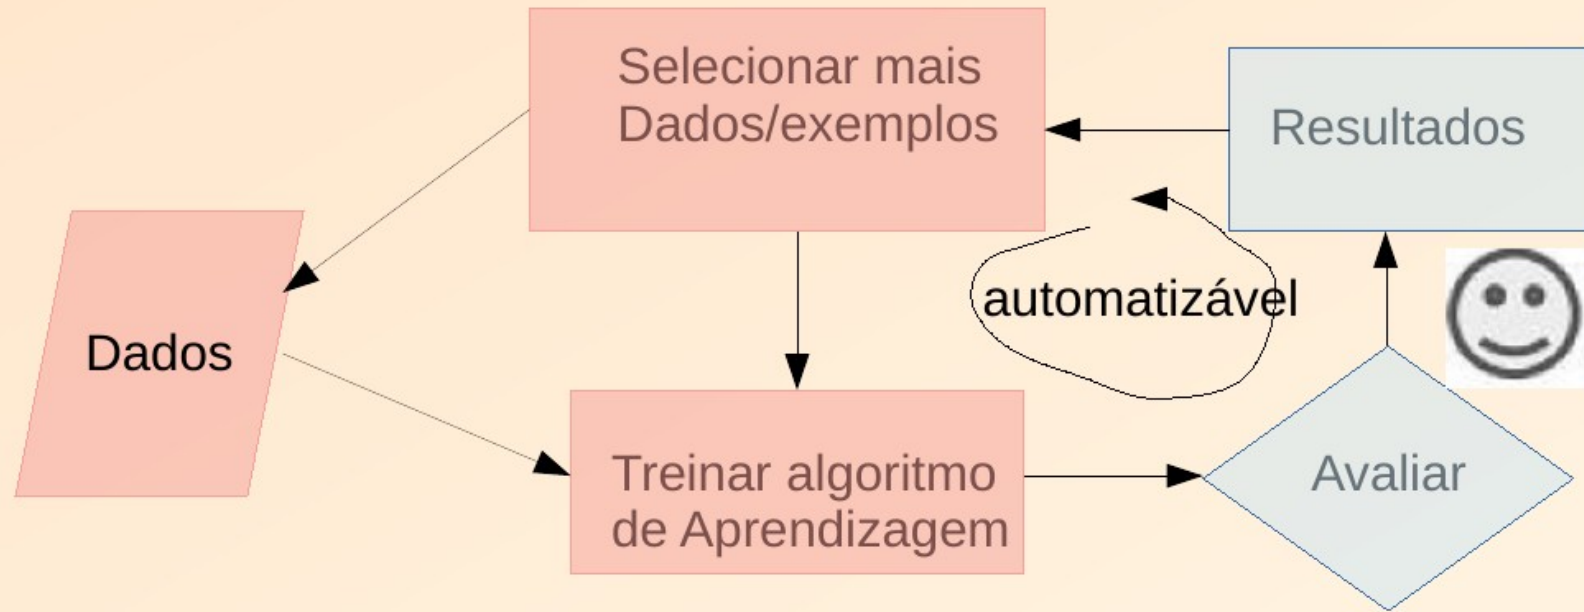
Exemplo: prog. Aprend. Máquina

- **Problema:** Escrever um programa que filtre e-mails “spam” no servidor.



Exemplo: prog. Aprend. Máquina

- Em Aprendizagem de Máquinas a estratégia pode ser adaptada constantemente.



Aprendizagem de Máquinas

- **Aprendizagem de Máquinas é programar computadores para uma tarefa (T), para otimizar um critério de desempenho (D), usando dados de exemplos ou experiência passada (E).**

Exemplo

- Programa que **aprende** a jogar damas (T)?

Exemplo


- .
- Programa que **aprende** a jogar damas **(T)**?
- Pode melhorar seu desempenho **(D)**, avaliando o número de vitórias (capacidade), através de experiência obtida em jogos passados **(E)**.

Exemplo

- Arthur Samuel (1959) escreveu um dos primeiros programas de Ap.Máquinas (IA) para jogar damas.



Arthur Samuel's checkers program on the IBM 701, 1956



Samuel, A. "Some Studies in Machine Learning Using the Game of Checkers," *IBM Journal* 3, 211-229 (1959).

Exemplo

- **Escolhas de projeto:**

T : Tarefa jogar damas;

P : Medida de desempenho = percentagem de jogos vencidos;

E : Experiência de treinamento = jogos contra o próprio programa;

Treinamento

Direto:

Indireto:

Exemplo

- **Escolhas de projeto:**

T : Tarefa jogar damas;

P : Medida de desempenho = percentagem de jogos vencidos;

E : Experiência de treinamento = jogos contra o próprio programa;

Treinamento

Direto: exemplos de movimentos individuais positivos/negativos;

Indireto:

Exemplo

- **Escolhas de projeto:**

T : Tarefa jogar damas;

P : Medida de desempenho = percentagem de jogos vencidos;

E : Experiência de treinamento = jogos contra o próprio programa;

Treinamento

Direto: exemplos de movimentos individuais positivos/negativos;

Indireto: sequências completas de movimentos (jogos) e resultado final;

Exemplo

- **Escolhas de projeto:**

T : Tarefa jogar damas;

P : Medida de desempenho = percentagem de jogos vencidos;

E : Experiência de treinamento = jogos contra o próprio programa;

Treinamento

Direto: exemplos de movimentos individuais positivos/negativos;

Indireto: sequências completas de movimentos (jogos) e resultado final;

Cenários de treinamento devem ser mais próximos da realidade (**validação**);

Exemplo

- **Escolhas de projeto:**

T : Tarefa jogar damas;

P : Medida de desempenho = percentagem de jogos vencidos;

E : Experiência de treinamento = jogos contra o próprio programa;

Treinamento

Direto: exemplos de movimentos individuais positivos/negativos;

Indireto: sequências completas de movimentos (jogos) e resultado final;

Cenários de treinamento devem ser mais próximos da realidade (**validação**);

Programa deve decidir o melhor movimento(jogada) para cada situação que se apresentar;

Exemplo

- **Escolhas de projeto:**

T : Tarefa jogar damas;

P : Medida de desempenho = percentagem de jogos vencidos;

E : Experiência de treinamento = jogos contra o próprio programa;

Treinamento

Direto: exemplos de movimentos individuais positivos/negativos;

Indireto: sequências completas de movimentos (jogos) e resultado final;

Cenários de treinamento devem ser mais próximos da realidade (**validação**);

Programa deve decidir o melhor movimento(jogada) para cada situação que se apresentar; → **Função de ganho**

Exemplo

- Seja por exemplo a seguinte função de ganho:

$$\hat{V}(b) = w_0 + w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + w_5x_5 + w_6x_6$$

w_0, w_1, \dots, w_6 são coeficientes a serem determinados

Exemplo

- Seja por exemplo a seguinte função de ganho:

$$\hat{V}(b) = w_0 + w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + w_5x_5 + w_6x_6$$

w_0, w_1, \dots, w_6 são coeficientes a serem determinados

X_1 : número de peças pretas

X_2 : número de peças brancas

X_3 : número de rainhas pretas

X_4 : número de rainhas brancas

X_5 : número de peças pretas ameaçadas (i.e. podem ser perdidas na próxima jogada)

X_6 : número de peças brancas ameaçadas (i.e. podem ser perdidas na próxima jogada)

Exemplo

- Seja por exemplo a seguinte função de ganho:

$$\hat{V}(b) = w_0 + w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + w_5x_5 + w_6x_6$$

w_0, w_1, \dots, w_6 são coeficientes a serem determinados

X_1 : número de peças pretas

X_2 : número de peças brancas

X_3 : número de rainhas pretas

X_4 : número de rainhas brancas

X_5 : número de peças pretas ameaçadas (i.e. podem ser perdidas na próxima jogada)

X_6 : número de peças brancas ameaçadas (i.e. podem ser perdidas na próxima jogada)

$V(b) = 100$ (vitória);

$V(b) = -100$ (derrota);

$V(b) = 0$ (empate);

Exemplo

- O treinamento será para ajustar/encontrar os melhores pesos w , dado um conjunto satisfatório de treinamento $\langle b, V(b) \rangle$

Exemplo

- O treinamento será para ajustar/encontrar os melhores pesos w , dado um conjunto satisfatório de treinamento $\langle b, V(b) \rangle$
- Por exemplo, um treinamento que minimize E

$$E \equiv \sum_{\langle b, V_{train}(b) \rangle \in \text{training examples}} (V_{train}(b) - \hat{V}(b))^2$$

Exemplo

- Por exemplo, inicializar com pesos baixos e aleatórios (normalizados);

Para cada exemplo de treinamento $\langle b, V_{train}(b) \rangle$

Use os valores atuais e calcule $\hat{V}(b)$

Para cada peso w_i

Atualizar para $w_i \leftarrow w_i + \eta (V_{train}(b) - \hat{V}(b)) x_i$

Regra *LMS* (*Least Mean Squares*)

0.1 (constante pequena)

Exemplo

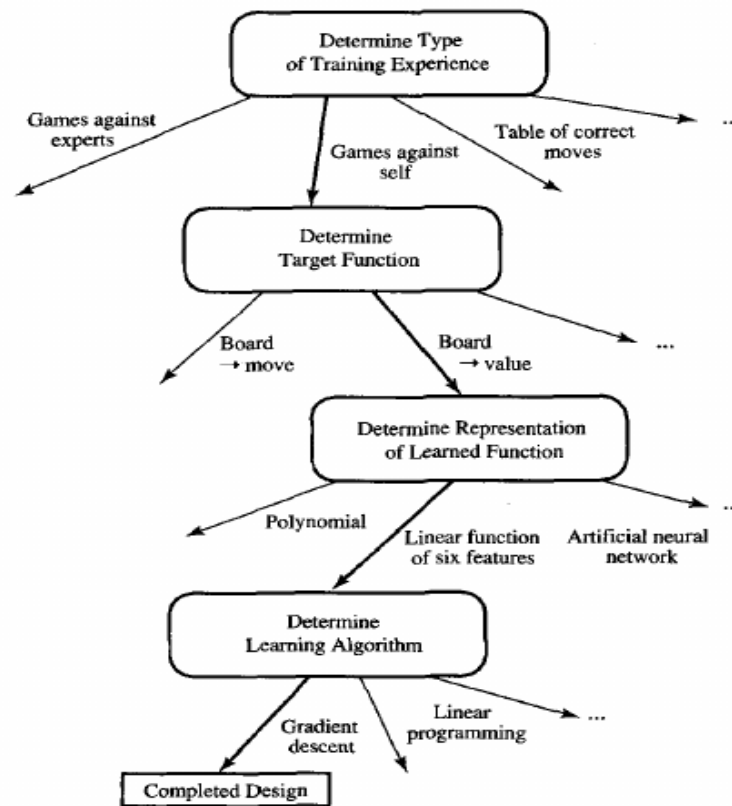


FIGURE 1.2
Summary of choices in designing the checkers learning program.

(Mitchell, 1997)

Generalização


- Um sistema/programa de aprendizado de máquina pode **resolver tarefas importantes/interessantes generalizando** a partir de **exemplos/dados/experiência**.

Generalização

- Um sistema/programa de aprendizado de máquina pode **resolver tarefas importantes/interessantes generalizando** a partir de **exemplos/dados/experiência**.
- A relação custo/benefício de se programar assim melhora na medida que mais dados ficam acessíveis/disponíveis.


Aprendizado de Máquina

Programação Tradicional




Aprendizado de Máquina

Programação Tradicional




Aprendizagem de Máquinas





Tipos de Aprendizagem

- 1) Aprendizagem Supervisionada



Tipos de Aprendizagem

- 1) Aprendizagem Supervisionada



Aprendizagem Supervisionada Ex: Regressão

- Given $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$
- Learn a function $f(x)$ to predict y given x
 - y is numeric == regression






Image: <https://www.flickr.com/photos/gsf/5937599688/>

Data from <https://nsidc.org/arcticseaicenews/sea-ice-tools/>

Aprendizagem Supervisionada Ex: Classificação

- Given $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$
- Learn a function $f(x)$ to predict y given x
 - y is categorical == classification




2 classes

Image: <https://eyecancer.com/uncategorized/choroidal-metastasis-test/>

Aprendizagem Supervisionada Ex: Classificação

- x can be multi-dimensional

- Each dimension corresponds to an attribute:



- Patient age
- Clump thickness
- Tumor Color
- Distance from optic nerve
- Cell type
- ...



Cell type is the most telling feature, but it's risky to do a biopsy of the eye


- ML can help determine *when* a feature is needed

multi-dimensional

Image: <https://eyecancer.com/uncategorized/choroidal-metastasis-test/>



Tipos de Aprendizagem

- 1) Aprendizagem Não Supervisionada



Tipos de Aprendizagem

- 1) Aprendizagem Não Supervisionada



Aprend. Não supervisionada Exemplo

- Independent component analysis – separate a combined signal into its original sources





Image credit: statsoft.com Audio from <http://www.ism.ac.jp/~shiro/research/blindsep.html>



Tipos de Aprendizagem

- 1) Aprendizagem Semi-supervisionada



Tipos de Aprendizagem

- 1) Aprendizagem Semi-supervisionada



Aprend. Semi-supervisionada Exemplo



Data

Documents

Sentences

Phrases

Images

Medical records

...

Labels

Politics, Sports, Finance

Positive, Negative


Person, Location

Cat, Dog, Snake, Horse

Re-admit soon/Not

Tipos de Aprendizagem

- 1) Aprendizagem por Reforço/Recompensa



Dados não rotulados (não supervisionado)

Reforço/recompensa possui atraso, e pode ser atribuída em sequências diferentes

Aprendizagem por Reforço (estratégia)

Aprendizagem por Reforço Exemplo



<https://www.youtube.com/watch?v=iaF43Ze1oel>

Aprendizagem: componentes

- Aprendizagem de Máquinas é aproximação de funções.

Aprendizagem: componentes

1o. passo: Construir/aprender/estimar a função de predição **$f()$**

Como? **$Y=f(X)$** **$X \rightarrow$ vetores de dados**

2o. passo: Aplicar **$f()$** em novas situações e predizer resposta

$Y'=f(X')$ **$X' \rightarrow$ vetores de novas situações**

Aprendizagem: componentes

- Aprendizagem de Máquinas é aproximação de funções.
- Embora existam centenas de algoritmos disponíveis, todos são combinações de 3 elementos essenciais:

Aprendizagem: componentes

- Aprendizagem de Máquinas é aproximação de funções.
- Embora existam centenas de algoritmos disponíveis, todos são combinações de 3 elementos essenciais:
 - 1) Representação
 - 2) Avaliação
 - 3) Otimização

Aprendizagem: componentes

Representação

Como os dados são especificados?

Qual é a forma do modelo?

Otimização

Como o modelo é treinado com os dados?

Avaliação

Quais são as medidas/métricas de desempenho?

Como avaliar se o modelo é satisfatório?

Aprendizagem: componentes

- Aprendizagem de Máquinas é aproximação de funções.
- Embora existam centenas de algoritmos disponíveis, todos são combinações de 3 elementos essenciais:
 - 1) Representação (linguagem formal, atributos)
 - 2) Avaliação
 - 3) Otimização

Aprendizagem: componentes

- Aprendizagem de Máquinas é aproximação de funções.
- Embora existam centenas de algoritmos disponíveis, todos são combinações de 3 elementos essenciais:
 - 1) Representação (linguagem formal, atributos)
 - 2) Avaliação (função de ganho/avaliar bons de resultados ruins)
 - 3) Otimização

Aprendizagem: componentes

- Aprendizagem de Máquinas é aproximação de funções.
- Embora existam centenas de algoritmos disponíveis, todos são combinações de 3 elementos essenciais:
 - 1) Representação (linguagem formal, atributos)
 - 2) Avaliação (função de ganho/avaliar bons de resultados ruins)
 - 3) Otimização (buscar entre os possíveis aqueles mais eficientes)

Aprendizagem: componentes

| Representation | Evaluation | Optimization |
|---------------------------|-----------------------|----------------------------|
| Instances | Accuracy/Error rate | Combinatorial optimization |
| K-nearest neighbor | Precision and recall | Greedy search |
| Support vector machines | Squared error | Beam search |
| Hyperplanes | Likelihood | Branch-and-bound |
| Naive Bayes | Posterior probability | Continuous optimization |
| Logistic regression | Information gain | Unconstrained |
| Decision trees | K-L divergence | Gradient descent |
| Sets of rules | Cost/Utility | Conjugate gradient |
| Propositional rules | Margin | Quasi-Newton methods |
| Logic programs | | Constrained |
| Neural networks | | Linear programming |
| Graphical models | | Quadratic programming |
| Bayesian networks | | |
| Conditional random fields | | |

(Domingos, 2012)

Aprendizagem: fluxo

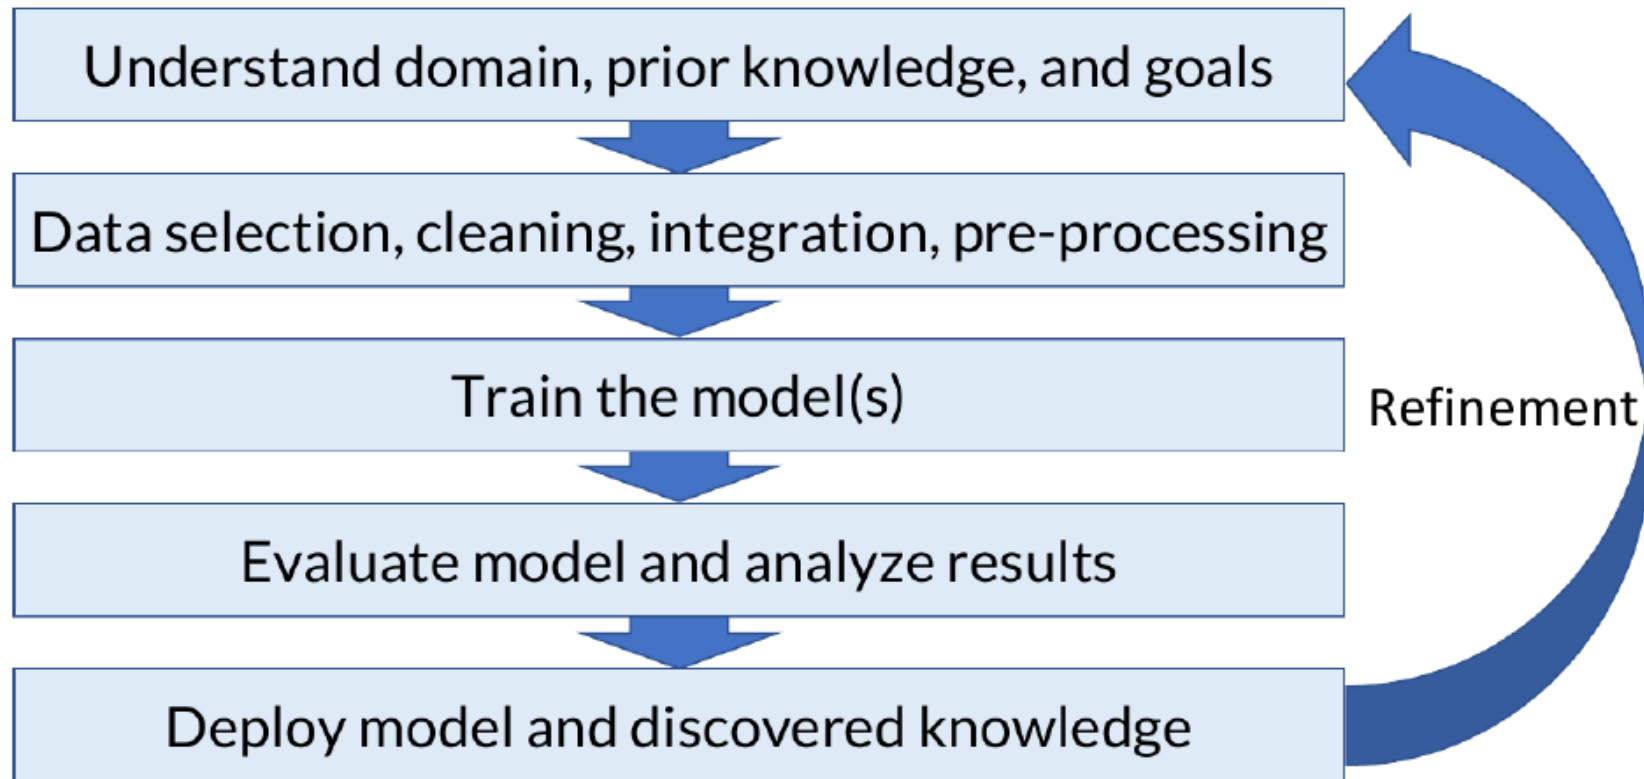
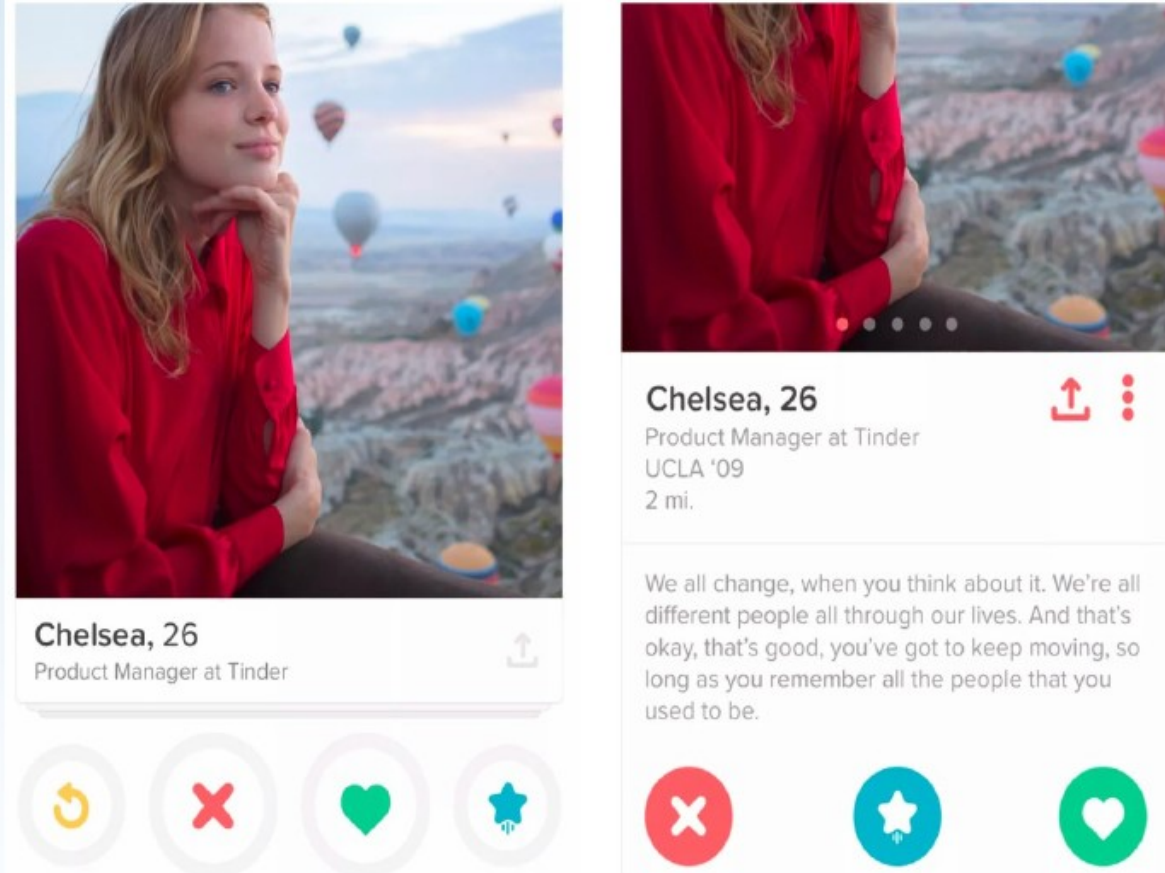



Imagem: E. Eaton

Exemplo de sistema por aprend(recomendação)



Slides/Images/Example Credit: E. Eaton (UPenn)

Exemplo de sistema por aprend(recomendação)



Buttercup13

Philadelphia, PA

Attended Post-grad, Doesn't smoke cigarettes, Drinks socially, Doesn't do drugs, Has dogs



Buttercup13

Philadelphia, PA

Attended Post-grad, Doesn't smoke cigarettes, Drinks socially, Doesn't do drugs, Has dogs
Add: politics, marijuana, diet, sign

ABOUT ME

My self-summary

I enjoy long walks on the beach, smooth appletinis, and witty banter about dragons. I have a weakness for 57% dark chocolate. "Excellent bicuspidis" - My dentist

Slides/Images/Example Credit: E. Eaton (UPenn)

Exemplo de sistema por aprend(recomendação)

The screenshot shows the OKCupid website interface. At the top, there's a navigation bar with the OKCupid logo and links for 'Browse Matches', 'DoubleTake', and 'Purchase A-List'. On the right, there are icons for a star, a speech bubble, and a profile picture.

On the left side, there's a sidebar with a large '99.8%' match percentage and the text 'Highest match possible'. Below this, it says 'You've answered 416 questions'. A list of categories is shown: PUBLIC (413), IMPORTANT (71), EXPLAINED (21), PRIVATE (3), and SKIPPED (116). The 'IMPORTANT' category is currently selected.

The main content area displays a grid of questions. Each question is labeled 'IMPORTANT TO YOU' and has a 'RE-ANSWER' button at the bottom. The questions are:

- Do humans and modern primates (apes, chimps, etc) share a common evolutionary ancestor?
 - ✓ Yes
 - No
 - Unsure
- Are you a cat person or a dog person?
 - Cats
 - ✓ Dogs
 - Both
 - Neither
- What's the highest level of education you've completed?
 - ✓ Graduate School
 - College
 - High School
 - Junior High
- Would you consider yourself a feminist?
 - ✓ Yes
 - No
 - To some extent
- Should we be fighting to close the gender wage gap?
 - ✓ Definitely, it's ridiculous there's a discrepancy
 - It's not top priority
 - What wage gap?
 - I don't care
- Do you enjoy intense intellectual conversations?
 - ✓ Yes
 - No

Slides/Images/Example Credit: E. Eaton (UPenn)

Exemplo de sistema por aprend(recomendação)

From a Profile to Features




Image source: <https://blog.photofeeler.com/best-tinder-bios-profile-tips/>

Slides/Images/Example Credit: E. Eaton (UPenn)

Exemplo de sistema por aprend(recomendação)

Obtaining User Feedback

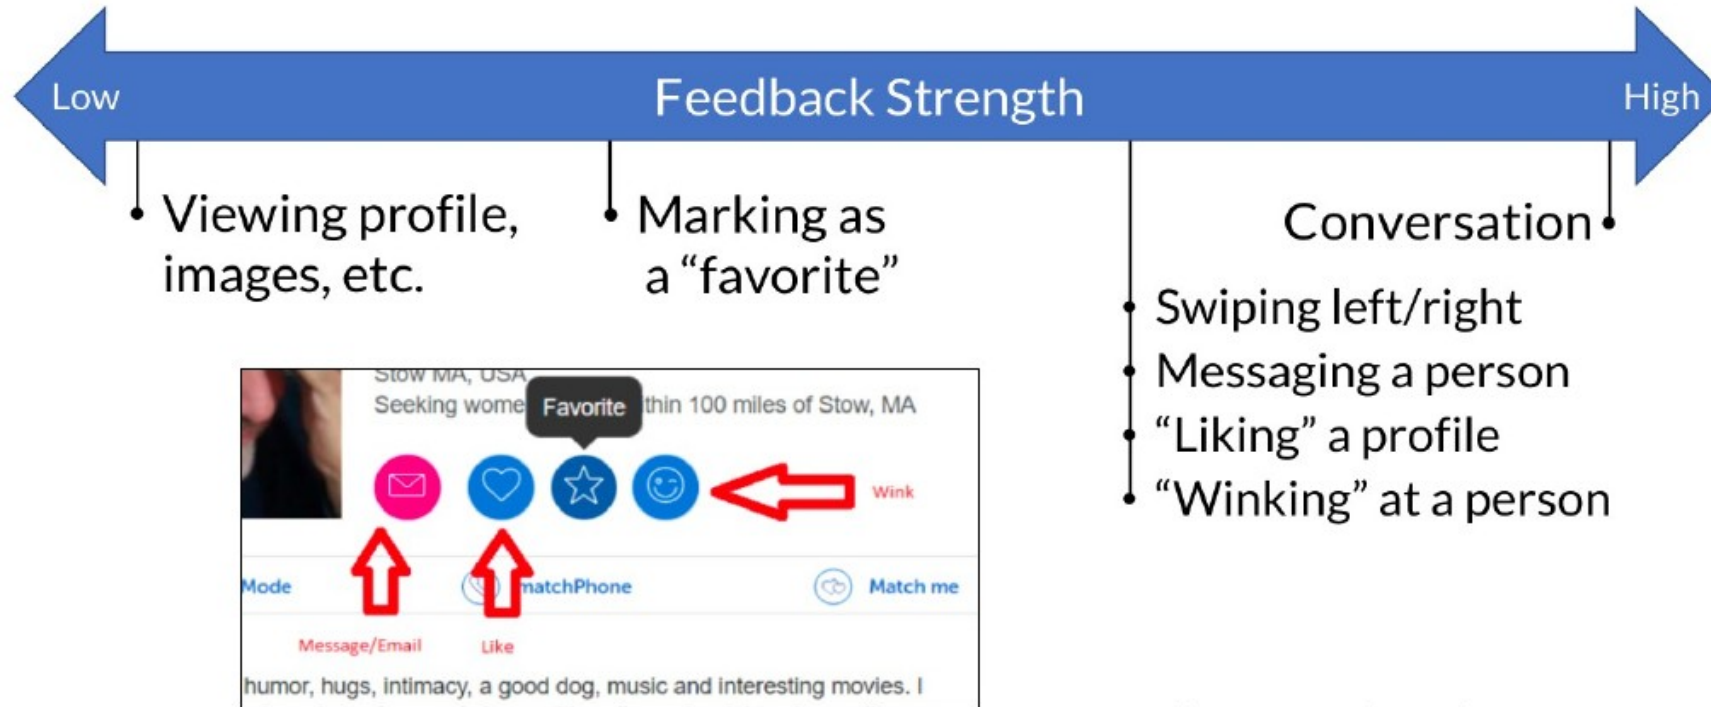


Image: <https://medium.com/icebrkr/breaking-down-the-complexity-issues-on-match-com-c0087dbddea2>

Slides/Images/Example Credit: E. Eaton (UPenn)

Exemplo de sistema por aprend(recomendação)

Getting Labeled Data




Image source: <https://blog.photofeeler.com/best-tinder-bio-profile-tips/>

Slides/Images/Example Credit: E. Eaton (UPenn)

Exemplo de sistema por aprend(recomendação)

Getting Labeled Data



Append feature vectors

Label

Image source: <https://blog.photofeeler.com/best-tinder-bios-profile-tips/>

Slides/Images/Example Credit: E. Eaton (UPenn)

Exemplo de sistema por aprend(recomendação)

Getting Labeled Data




Image: <https://blog.photofeeler.com/best-tinder-bios-profile-tips/>

Slides/Images/Example Credit: E. Eaton (UPenn)

Exemplo de sistema por aprend(recomendação)

Forming the Training Data




Image: <https://blog.photofeeler.com/best-tinder-bios-profile-tips/>

Slides/Images/Example Credit: E. Eaton (UPenn)

Exemplo de sistema por aprend(recomendação)

Forming the Training Data


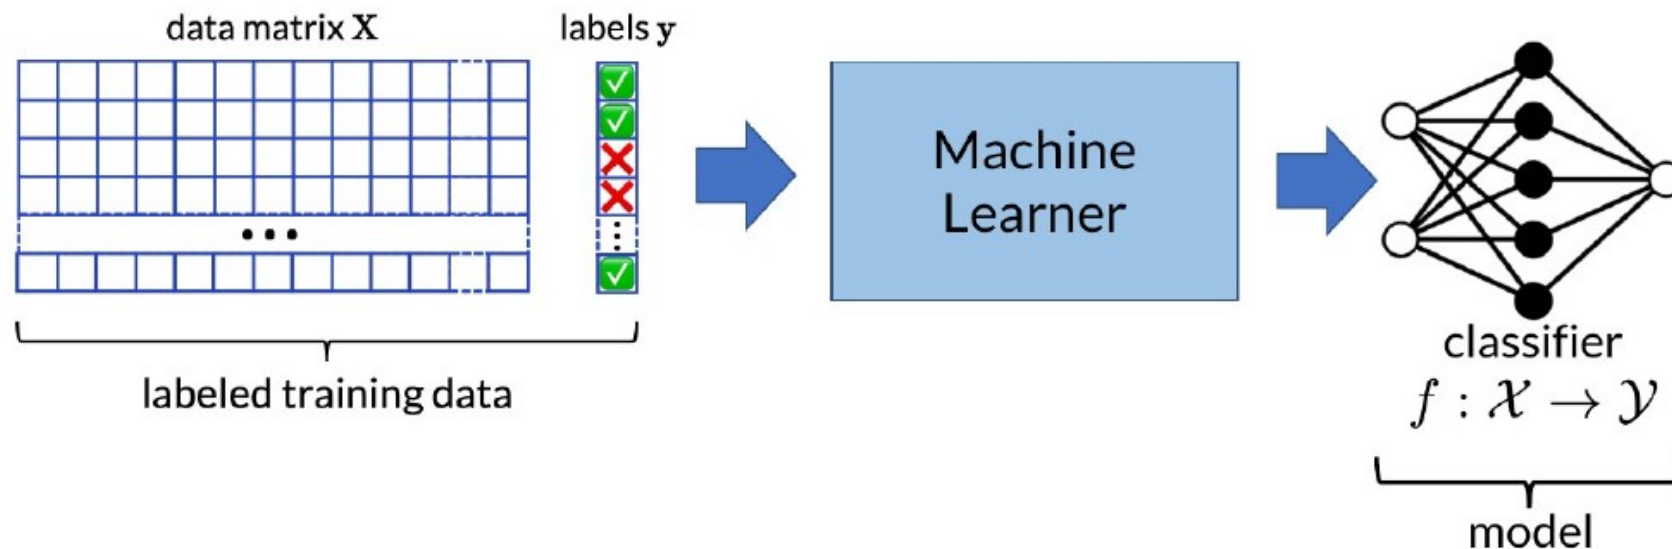


Image: <https://blog.photofeeler.com/best-tinder-bios-profile-tips/>

Slides/Images/Example Credit: E. Eaton (UPenn)

Exemplo de sistema por aprend(recomendação)

Training the Model



Slides/Images/Example Credit: E. Eaton (UPenn)

Exemplo de sistema por aprend(recomendação)




Image: <https://blog.photofeeler.com/best-tinder-bios-profile-tips/>

Slides/Images/Example Credit: E. Eaton (UPenn)

Exemplo de sistema por aprend(recomendação)

Framing as a Recommendation Problem

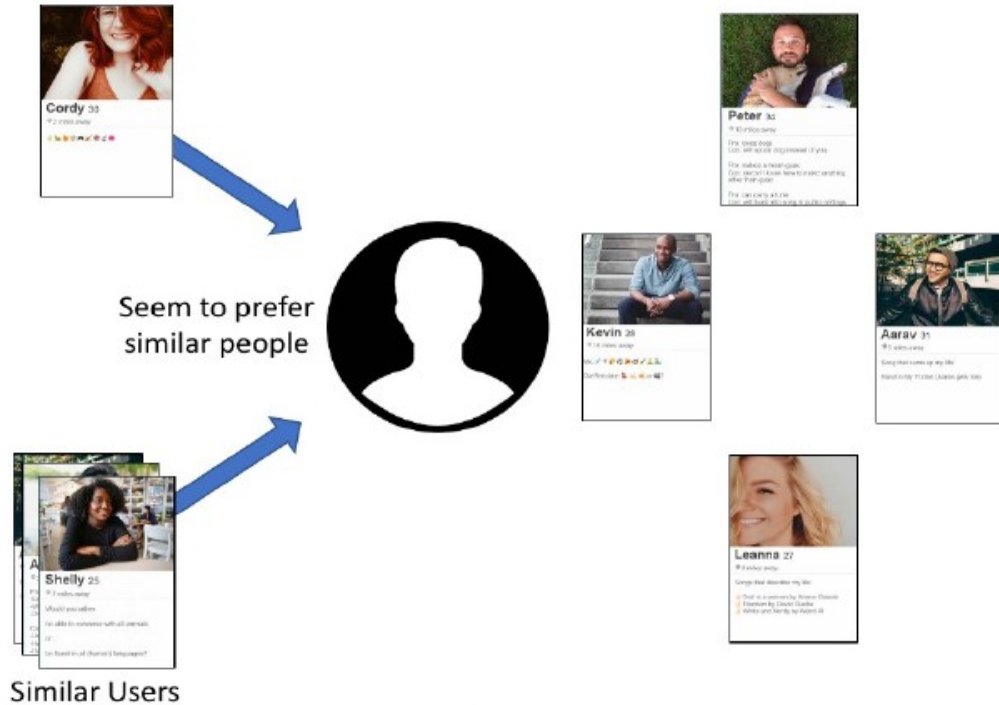


Image: <https://blog.photofeeler.com/best-tinder-bios-profile-tips/>

Slides/Images/Example Credit: E. Eaton (UPenn)

Leitura

- Ler artigo

Domingos, P. A few useful things about machine learning,
Communications of the ACM, 55 (10), 78-87, 2012.

Referências

- Russel & Norvig, Artificial Intelligence: a modern approach (4th ed), Pearson, 2020. (Cap. 19)
- Mitchell, T. *Machine Learning*, McGraw-Hill, 1997.
- Géron, A. *Hands-On Machine Learning with Scikit-Learn & TensorFlow*, O'Reilly Inc., 2017.