


“Para o prazer e para ser feliz, é que é preciso a gente saber tudo,
formar alma, na consciência; para penar, não se carece.”

(Guimarães Rosa *in* **Grande Sertão: Veredas**, 1956)




Introdução à Inteligência Artificial

Roteiro da aula:

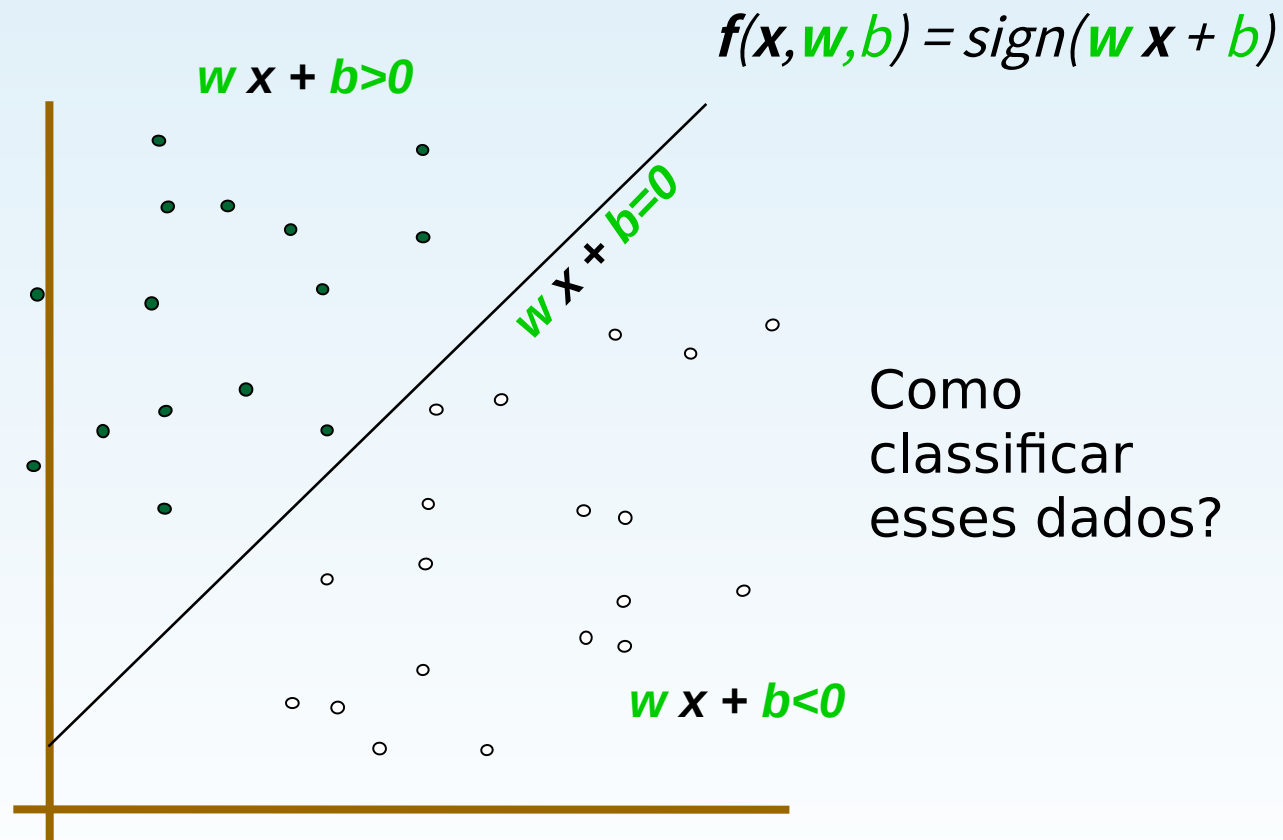
- ♦ **Máquinas de Vetores de Suporte (SVM)**

Máquinas de Vetores de Suporte. Material baseado, com ilustrações, no Cap. 9 de “Introduction to Statistical Learning”, James, Witten, Hastie & Tibshirani, Springer, 2017.


De classificadores lineares por funções discriminantes



- indica +1
- indica -1




De classificadores lineares por funções discriminantes




$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \mathbf{x} + b)$$

- indica +1
- indica -1



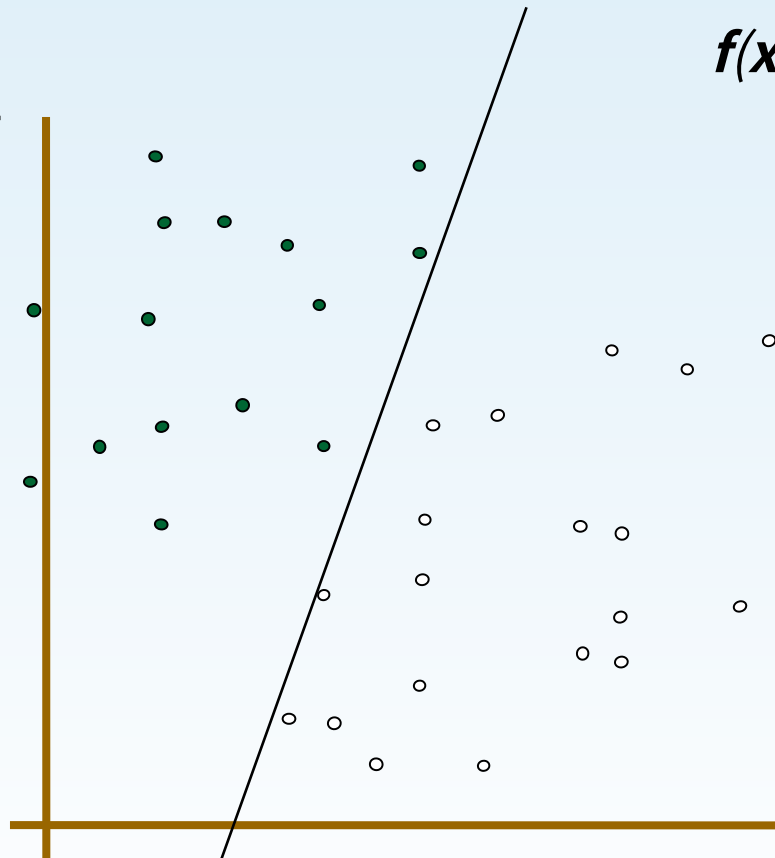
Como
classificar
esses dados?

De classificadores lineares por funções discriminantes




$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \mathbf{x} + b)$$

- indica +1
- indica -1




Como
classificar
esses dados?

De classificadores lineares por funções discriminantes



- indica +1
- indica -1




$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \mathbf{x} + b)$$

Qualquer
destas seria
ok...

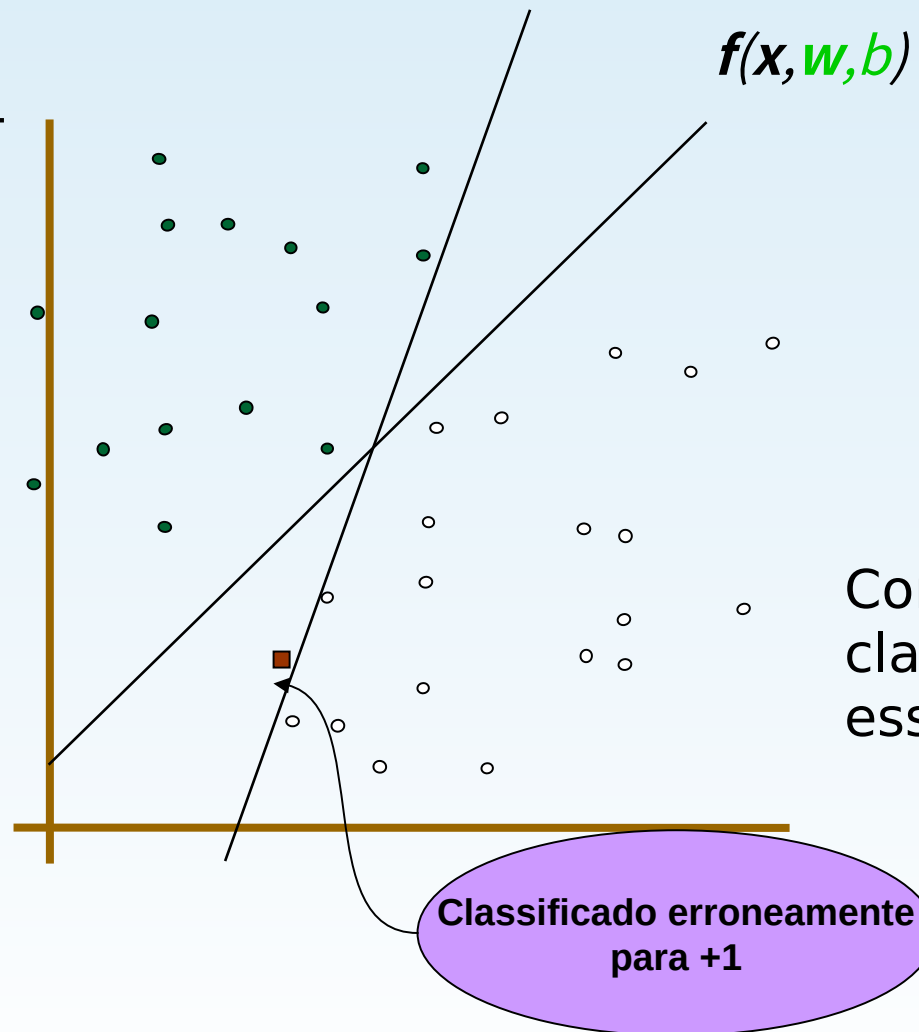
..mas qual é
melhor?

De classificadores lineares por funções discriminantes




- indica +1
- indica -1

$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \mathbf{x} + b)$$




Como
classificar
esses dados?

Margem



$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \mathbf{x} + b)$$

- indica +1
- indica -1




Definir a **margem** de um classificador linear como a largura que o contorno poderia ser aumentado até encontrar um dado(ponto).

Ao maximizar a margem diminuem-se os modelos possíveis


De classificadores lineares por funções discriminantes

Margem
Máxima




Vetores de
Suporte

são os pontos
na borda da
margem



De classificadores lineares por funções discriminantes


Margem
Máxima



- indica +1
- indica -1

Vetores de
Suporte

são os pontos
na borda da
margem

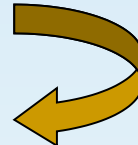


1. Maximizar a margem é uma boa ideia.
2. Implica que somente vetores de suporte são importantes; outros elementos no treinamento são ignoráveis.
3. Empiricamente funciona muito bem.

SVM Linear

SVM Linear algoritmo

- Meta: 1) Corretamente classificar todos os dados de treinamento

$$\begin{array}{ll} wx_i + b \geq 1 & \text{if } y_i = +1 \\ wx_i + b \leq 1 & \text{if } y_i = -1 \\ y_i(wx_i + b) \geq 1 & \text{for all } i \end{array} \quad \left. \vphantom{\begin{array}{l} wx_i + b \geq 1 \\ wx_i + b \leq 1 \end{array}} \right\} \quad \text{}$$



2) Maximizar a Margem $M = \frac{2}{|w|}$
mesmo que minimizar $\frac{1}{2} w^t w$

- Podemos formular um Problema de Otimização Quadrática e resolver para w e b

- Minimizar $\Phi(w) = \frac{1}{2} w^t w$


sujeito a $y_i(wx_i + b) \geq 1 \quad \forall i$

Hiperplano Margem Máxima



imagem/slide: E.Eaton

Vetores de Suporte



Classificador Vetor de Suporte (SVM)

Hiperplano Separador Ótimo

$$X = \{\mathbf{x}^t, r^t\}_t \text{ where } r^t = \begin{cases} +1 & \text{if } \mathbf{x}^t \in C_1 \\ -1 & \text{if } \mathbf{x}^t \in C_2 \end{cases}$$

find \mathbf{w} and w_0 such that

$$\mathbf{w}^T \mathbf{x}^t + w_0 \geq +1 \text{ for } r^t = +1$$

$$\mathbf{w}^T \mathbf{x}^t + w_0 \leq -1 \text{ for } r^t = -1$$

which can be rewritten as

$$r^t (\mathbf{w}^T \mathbf{x}^t + w_0) \geq +1$$

(Cortes and Vapnik, 1995; Vapnik, 1995)

Classificador Vetor de Suporte (SVM)


Margem

- Distância do discriminante às instâncias mais próximas em ambos os lados
- Distância de \mathbf{x} para o hiperplano é $\frac{|\mathbf{w}^T \mathbf{x}^t + w_0|}{\|\mathbf{w}\|}$
- Requer-se $\frac{r^t(\mathbf{w}^T \mathbf{x}^t + w_0)}{\|\mathbf{w}\|} \geq \rho, \forall t$
- Para uma solução única, fixar $\rho \|\mathbf{w}\| = 1$, e para margem máxima

$$\min \frac{1}{2} \|\mathbf{w}\|^2 \text{ subject to } r^t(\mathbf{w}^T \mathbf{x}^t + w_0) \geq +1, \forall t$$

Classificador Vetor de Suporte (SVM)

Margem



Classificador Vetor de Suporte (SVM)

$$\min \frac{1}{2} \|\mathbf{w}\|^2 \text{ subject to } r^t(\mathbf{w}^T \mathbf{x}^t + w_0) \geq +1, \forall t$$

$$\begin{aligned} L_p &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{t=1}^N \alpha^t [r^t(\mathbf{w}^T \mathbf{x}^t + w_0) - 1] \\ &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{t=1}^N \alpha^t r^t(\mathbf{w}^T \mathbf{x}^t + w_0) + \sum_{t=1}^N \alpha^t \end{aligned}$$

$$\frac{\partial L_p}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{t=1}^N \alpha^t r^t \mathbf{x}^t$$

$$\frac{\partial L_p}{\partial w_0} = 0 \Rightarrow \sum_{t=1}^N \alpha^t r^t = 0$$

Classificador Vetor de Suporte (SVM)

$$\begin{aligned} L_d &= \frac{1}{2} (\mathbf{w}^T \mathbf{w}) - \mathbf{w}^T \sum_t \alpha^t r^t \mathbf{x}^t - w_0 \sum_t \alpha^t r^t + \sum_t \alpha^t \\ &= -\frac{1}{2} (\mathbf{w}^T \mathbf{w}) + \sum_t \alpha^t \\ &= -\frac{1}{2} \sum_t \sum_s \alpha^t \alpha^s r^t r^s (\mathbf{x}^t)^T \mathbf{x}^s + \sum_t \alpha^t \\ \text{subject to } \sum_t \alpha^t r^t &= 0 \text{ and } \alpha^t \geq 0, \forall t \end{aligned}$$

Muitos α^t são 0 e somente um pequeno número tem $\alpha^t > 0$; eles são os vetores de suporte

Hiperplanos Separáveis

- Imagine uma situação onde tem-se um problema de classificação com duas classes e dois preditores X_1 e X_2 .

Hiperplanos Separáveis

- Imagine uma situação onde tem-se um problema de classificação com duas classes e dois preditores X_1 e X_2 .
- Suponha que as duas classes são “separáveis linearmente” i.e. pode-se desenhar uma reta onde todos os pontos de um lado pertencem à primeira classe, e pontos do outro lado à segunda classe.



Hiperplanos Separáveis

- Imagine uma situação onde tem-se um problema de classificação com duas classes e dois preditores X_1 e X_2 .
- Suponha que as duas classes são “separáveis linearmente” i.e. pode-se desenhar uma reta onde todos os pontos de um lado pertencem à primeira classe, e pontos do outro lado à segunda classe.
- Então uma abordagem direta é encontrar uma linha reta que forneça a maior separação entre as classes i.e. os pontos estão o mais distante da linha quanto possível.

Hiperplanos Separáveis

- Imagine uma situação onde tem-se um problema de classificação com duas classes e dois preditores X_1 e X_2 .
- Suponha que as duas classes são “separáveis linearmente” i.e. pode-se desenhar uma reta onde todos os pontos de um lado pertencem à primeira classe, e pontos do outro lado à segunda classe.
- Então uma abordagem direta é encontrar uma linha reta que forneça a maior separação entre as classes i.e. os pontos estão o mais distante da linha quanto possível.
- Esta é a ideia básica de um classificador vetor de suporte.

Hiperplanos Separáveis



- If $f(X) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$, then $f(X) > 0$ for points on one side of the hyperplane, and $f(X) < 0$ for points on the other.
- If we code the colored points as $Y_i = +1$ for blue, say, and $Y_i = -1$ for mauve, then if $Y_i \cdot f(X_i) > 0$ for all i , $f(X) = 0$ defines a *separating hyperplane*.


Hiperplanos Separáveis

Equação de um Hiperplano

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p = 0$$


Hiperplanos Separáveis

Exemplo de um Hiperplano




Hiperplanos Separáveis

Hiperplano em 2 dimensões




Encontrando Hiperplanos

- C é a distância perpendicular mínima entre cada ponto e a reta separadora.




Encontrando Hiperplanos

- C é a distância perpendicular mínima entre cada ponto e a reta separadora.
- Encontramos a reta que maximiza C .




Encontrando Hiperplanos

- C é a distância perpendicular mínima entre cada ponto e a reta separadora.
- Encontramos a reta que maximiza C .
- Essa reta é chamada de “hiperplano separador ótimo”.



Encontrando Hiperplanos

- C é a distância perpendicular mínima entre cada ponto e a reta separadora.
- Encontramos a reta que maximiza C .
- Essa reta é chamada de “hiperplano separador ótimo”
- A classificação de um ponto depende de qual lado da reta ele fica.



Encontrando Hiperplanos



maximize M
 $\beta_0, \beta_1, \dots, \beta_p$

subject to $\sum_{j=1}^p \beta_j^2 = 1,$

$y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq M$
for all $i = 1, \dots, N.$



Encontrando Hiperplanos

Mas, os dados podem ser ruidosos, ou não haver separabilidade entre classes



SVM

Usar C como regularizador, parâmetro de equilíbrio encontrando vetores de suporte ao hiperplano



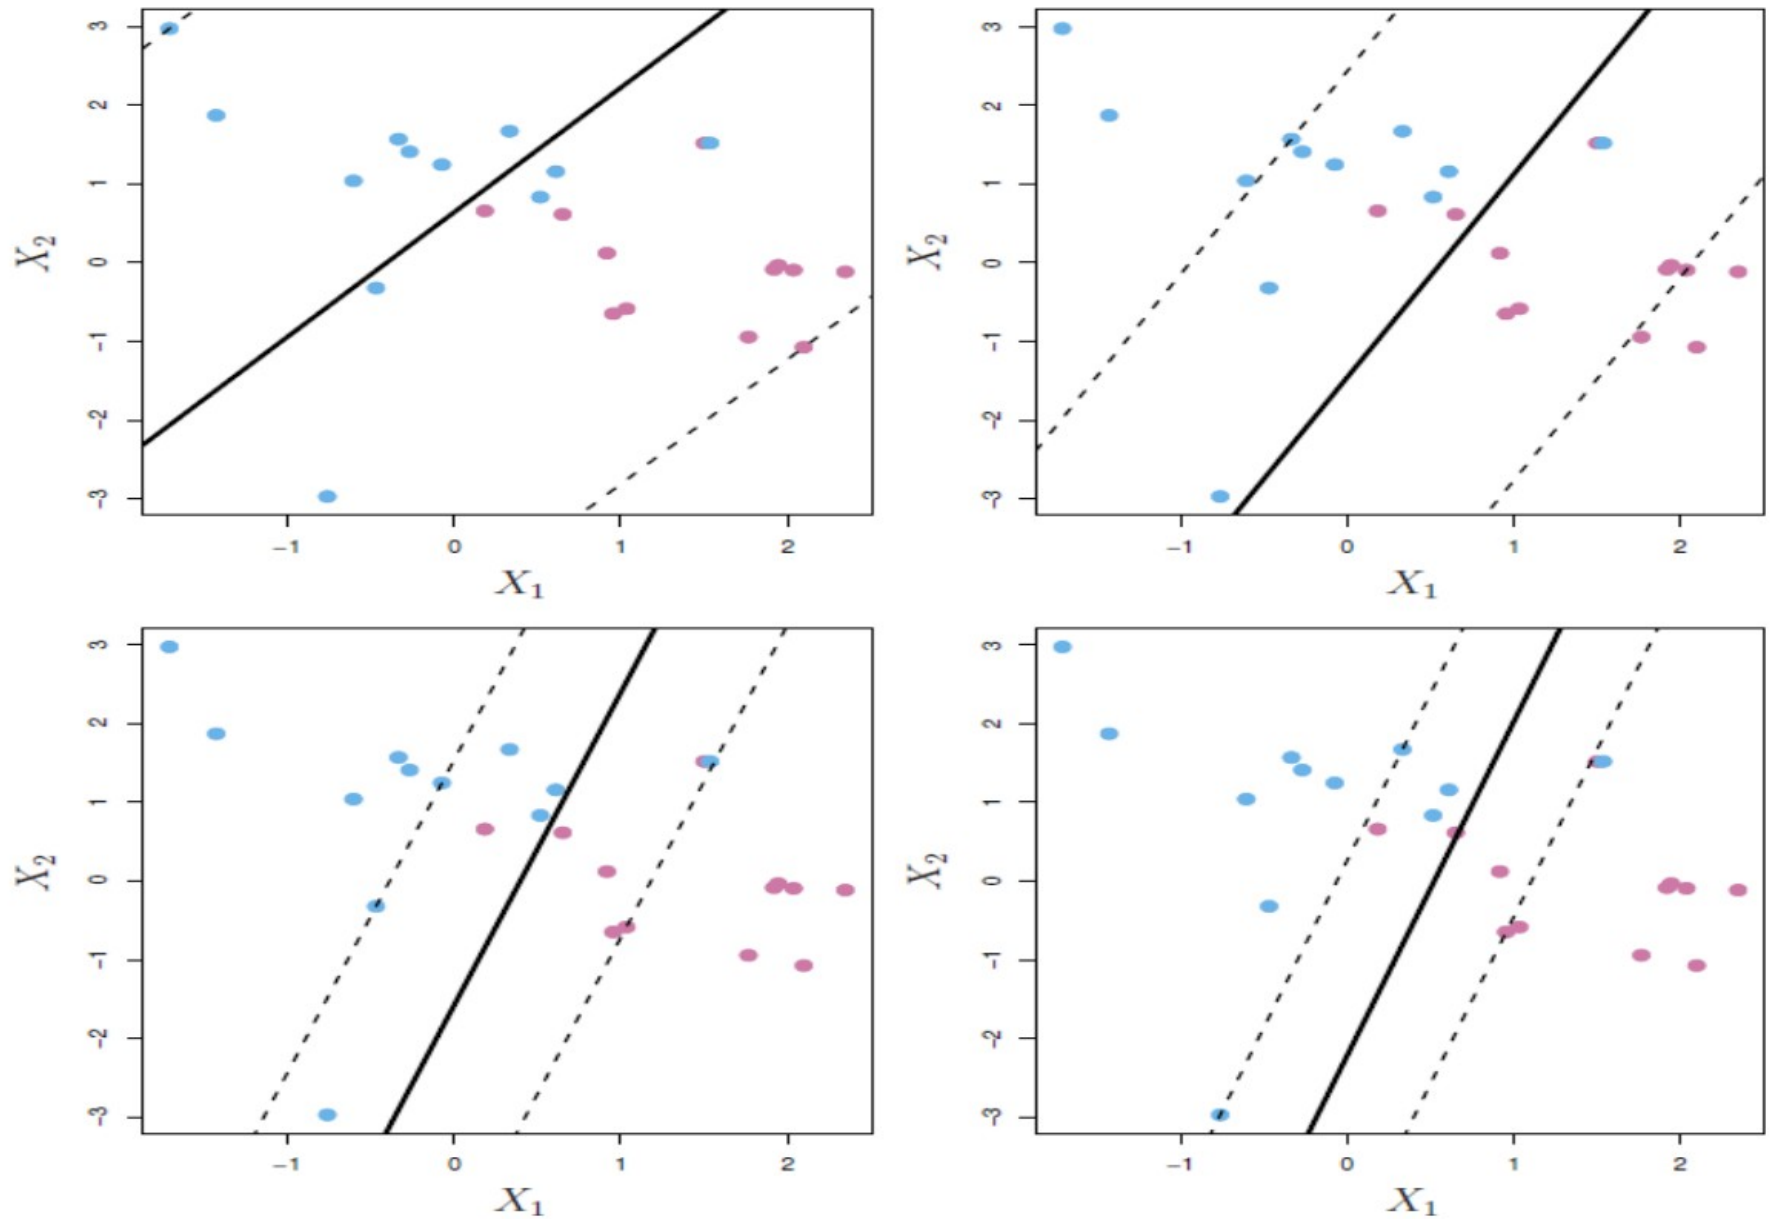
$$\underset{\beta_0, \beta_1, \dots, \beta_p, \epsilon_1, \dots, \epsilon_n}{\text{maximize}} \quad M \quad \text{subject to} \quad \sum_{j=1}^p \beta_j^2 = 1,$$

$$y_i(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}) \geq M(1 - \epsilon_i),$$

$$\epsilon_i \geq 0, \quad \sum_{i=1}^n \epsilon_i \leq C,$$

SVM


Usar C como regularizador, parâmetro de equilíbrio encontrando vetores de suporte ao hiperplano



SVM

Support Vector Machine

linearly separable data



Classes sem separação exata

- Na prática não é usualmente possível encontrar um hiperplano que separe perfeitamente duas classes.

Classes sem separação exata

- Na prática não é usualmente possível encontrar um hiperplano que separe perfeitamente duas classes.
- Haverá pelo menos alguns pontos no lado errado da reta.

Classes sem separação exata


- Na prática não é usualmente possível encontrar um hiperplano que separa perfeitamente duas classes.
- Haverá pelo menos alguns pontos no lado errado da reta.
- Nessa situação tentamos encontrar um plano que dá a melhor separação entre os pontos que são corretamente classificados sujeitos a pontos do lado errado em pequena quantidade.

SVM (Flexibilizar Margem)

Variáveis que permitam folga ξ_i podem ser adicionados para permitir algumas classificações errôneas, difíceis ou ruídos.

- Seja ξ_i^* representando a quantia que o i -ésimo ponto está no lado errado da margem (a reta espaçada).


$$\begin{aligned} \min_{\theta} & \frac{1}{2} \sum_{j=1}^d \theta_j^2 + C \sum_i \xi_i \\ \text{s.t. } & y_i (\theta^\top x_i) \geq 1 - \xi_i \quad \forall i \end{aligned}$$



SVM (Flexibilizar Margem)

- Seja ξ_i^* representando a quantia que o i -ésimo ponto está no lado errado da margem (a reta espaçada).
- Então queremos maximizar C sujeito a

$$\frac{1}{C} \sum_{i=1}^n \xi_i^* \leq \text{Constant}$$




SVM (Flexibilizar Margem)

- Seja ξ_i^* representando a quantia que o i -ésimo ponto está no lado errado da margem (a reta espaçada).
- Então queremos maximizar C sujeito a

$$\frac{1}{C} \sum_{i=1}^n \xi_i^* \leq \text{Constant}$$

- A constante é um parâmetro de ajuste que escolhemos.



Margem Rígida vs. Flexível

- **Rígida:**

Encontrar \mathbf{w} e \mathbf{b} tais que

$\Phi(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \mathbf{w}$ é minimizada e para todos $\{(\mathbf{x}_i, y_i)\}$

$$y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

- **Flexível (incorporando variáveis de folga):**

Encontrar \mathbf{w} e \mathbf{b} tais que


$\Phi(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum \xi_i$ é minimizada e para todos $\{(\mathbf{x}_i, y_i)\}$

$$y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad \text{e} \quad \xi_i \geq 0 \text{ para todos } i$$

- **Parâmetro C pode ser visto como uma forma de controlar sobreajuste.**



Exemplo com constante pequena

- A distância entre as retas representa a margem ou $2C$.
- As curvas púrpuras representam os contornos de decisão de Bayes



Exemplo constante maior


- Usando uma constante maior permite uma margem mais larga e cria um classificador diferente.
- Note, contudo, que o contorno de decisão mantém-se linear.



Classificador por “Máquina de Vetor de Suporte”


Classificador por “Máquina de Vetor de Suporte”

- Às vezes, independente da escolha de C , uma separação linear não existirá.
- O que fazer?




SVM Não-linear

- Ideia geral: o espaço de entrada original pode ser mapeado para algum espaço de atributos de maior dimensão onde o conjunto de treinamento seja separável:



SVM Não-linear

Mapping into a New Feature Space



- For example, with $x \in \mathbb{R}^2$, let $\Phi([x_{i1}, x_{i2}]) = [x_{i1}, x_{i2}, x_{i1}x_{i2}, x_{i1}^2, x_{i2}^2]$
- Rather than run SVM on x_i , run it on $\Phi(x_i)$
 - Finds a non-linear separator in the input space

This is just a basis expansion

What if $\Phi(x_i)$ is really big?

- Use kernels to compute it **implicitly**!

Classificador por “Máquina de Vetor de Suporte”

- O classificador de vetor de suporte permite, contudo, somente contorno linear de decisão.

Classificador por “Máquina de Vetor de Suporte”

- O classificador de vetor de suporte permite, contudo, somente contorno linear de decisão.
- Pode-se estender regressão linear para regressão não-linear usando funções de base $b_i(X_i)$ i.e.

$$Y_i = \beta_0 + \beta_1 b_1(X_i) + \beta_2 b_2(X_i) + \cdots + \beta_p b_p(X_i) + \varepsilon_i$$

“Kernel trick”

- O classificador linear suporta-se no produto interno entre vetores $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$
- Se todo ponto de dados é transformado em um espaço de maior dimensão via alguma transformação $\Phi: \mathbf{x} \rightarrow \phi(\mathbf{x})$, o produto interno torna-se:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

- Uma *função de kernel* é alguma função que corresponda ao produto interno em algum espaço de atributos expandido.
- Exemplo:

vetores bidimensionais $\mathbf{x} = [x_1 \ x_2]$; Seja $K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i^T \mathbf{x}_j)^2$,

Necessário mostrar que $K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$:

$$\begin{aligned} K(\mathbf{x}_i, \mathbf{x}_j) &= (1 + \mathbf{x}_i^T \mathbf{x}_j)^2, \\ &= 1 + x_{i1}^2 x_{j1}^2 + 2 x_{i1} x_{j1} x_{i2} x_{j2} + x_{i2}^2 x_{j2}^2 + 2 x_{i1} x_{j1} + 2 x_{i2} x_{j2} \\ &= [1 \ x_{i1}^2 \ \sqrt{2} x_{i1} x_{i2} \ x_{i2}^2 \ \sqrt{2} x_{i1} \ \sqrt{2} x_{i2}]^T [1 \ x_{j1}^2 \ \sqrt{2} x_{j1} x_{j2} \ x_{j2}^2 \ \sqrt{2} x_{j1} \ \sqrt{2} x_{j2}] \\ &= \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j), \quad \text{onde } \phi(\mathbf{x}) = [1 \ x_1^2 \ \sqrt{2} x_1 x_2 \ x_2^2 \ \sqrt{2} x_1 \ \sqrt{2} x_2] \end{aligned}$$

Classificador por “Máquina de Vetor de Suporte”: Expansão de Atributos

- Aumentar o espaço de atributos (características) incluindo transformações: $X_1^2, X_1^3, X_1X_2, X_1X_2^2, \dots$
- Indo de um espaço com p dimensões a $M > p$
- Ajustar um classificador SVM no espaço aumentado
- Isso resultará em contornos não-lineares de decisão no espaço original
- Exemplo: $(X_1, X_2, X_1^2, X_2^2, X_1X_2)$

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1^2 + \beta_4 X_2^2 + \beta_5 X_1 X_2 = 0$$

Abordagem básica SVM não-linear

- Conceitualmente, fazemos uma abordagem similar com o classificador vetor de suporte.
- O classificador vetor de suporte encontra o hiperplano ótimo no espaço gerado por X_1, X_2, \dots, X_p .

Abordagem básica SVM não-linear


- Conceitualmente, fazemos uma abordagem similar com o classificador vetor de suporte.
- O classificador vetor de suporte encontra o hiperplano ótimo no espaço gerado por X_1, X_2, \dots, X_p .
- Podemos criar transformações (ou uma base) $b_1(x), b_2(x), \dots, b_M(x)$ e encontrar o hiperplano ótimo no espaço gerado por $b_1(\mathbf{X}), b_2(\mathbf{X}), \dots, b_M(\mathbf{X})$.

Abordagem básica SVM não-linear

- Conceitualmente, fazemos uma abordagem similar com o classificador vetor de suporte.
- O classificador vetor de suporte encontra o hiperplano ótimo no espaço gerado por X_1, X_2, \dots, X_p .
- Podemos criar transformações (ou uma base) $b_1(x), b_2(x), \dots, b_M(x)$ e encontrar o hiperplano ótimo no espaço gerado por $b_1(\mathbf{X}), b_2(\mathbf{X}), \dots, b_M(\mathbf{X})$.
- Essa abordagem produz um plano linear no espaço transformado mas um contorno de decisão não-linear no espaço original.
- Isso é chamado de Classificador por Máquina de Vetor de Suporte.

Exemplo

Polinômios cúbicos



$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1^2 + \beta_4 X_2^2 + \beta_5 X_1 X_2 + \beta_6 X_1^3 + \beta_7 X_2^3 + \beta_8 X_1 X_2^2 + \beta_9 X_1^2 X_2 = 0$$

Mas, na prática

- Conceitualmente a abordagem básica é como SVM funciona realmente, mas não escolhemos $b_1(x)$, $b_2(x)$, ..., $b_M(x)$.
- Ao invés, escolhemos algo chamado de função Kernel (ou radial) que toma o lugar da base.
- Funções comuns “kernel” incluem
 - Linear
 - Polinomial
 - Base Radial
 - Sigmóide

Mas, na prática


- Ao invés, escolhemos algo chamado de função Kernel (ou radial) que toma o lugar da base.
- Funções comuns “kernel” incluem
 - Linear $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$
 - Polinomial $K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i^T \mathbf{x}_j)^p$
 - Base Radial $K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$
 - Sigmóide $K(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta_0 \mathbf{x}_i^T \mathbf{x}_j + \beta_1)$

Exemplo

Exemplo com kernel polinomial

- Usando um kernel polinomial permitimos ao SVM produzir um contorno de decisão não-linear.
- Note que a taxa de erro de teste é bem menor.

SVM - Degree-4 Polynomial in Feature Space




Exemplo


Exemplo, base radial

- Usando um Kernel de Base Radial consegue-se uma taxa de erro ainda menor.

SVM - Degree-4 Polynomial in Feature Space



SVM - Radial Kernel in Feature Space



SVM para mais de 2 classes?

OVA One versus All. Fit K different 2-class SVM classifiers $\hat{f}_k(x)$, $k = 1, \dots, K$; each class versus the rest. Classify x^* to the class for which $\hat{f}_k(x^*)$ is largest.

SVM para mais de 2 classes?

OVA One versus All. Fit K different 2-class SVM classifiers $\hat{f}_k(x)$, $k = 1, \dots, K$; each class versus the rest. Classify x^* to the class for which $\hat{f}_k(x^*)$ is largest.

OVO One versus One. Fit all $\binom{K}{2}$ pairwise classifiers $\hat{f}_{k\ell}(x)$. Classify x^* to the class that wins the most pairwise competitions.

Exemplo de Aplicação

Application: Pedestrian detection in Computer Vision

Objective: detect (localize) standing humans in an image

- cf face detection with a sliding window classifier



- reduces object detection to binary classification

- does an image window contain a person or not?

Method: the HOG detector

(Dalal & Triggs, 2005)


Exemplo de Aplicação

Training data and features

- Positive data – 1208 positive window examples



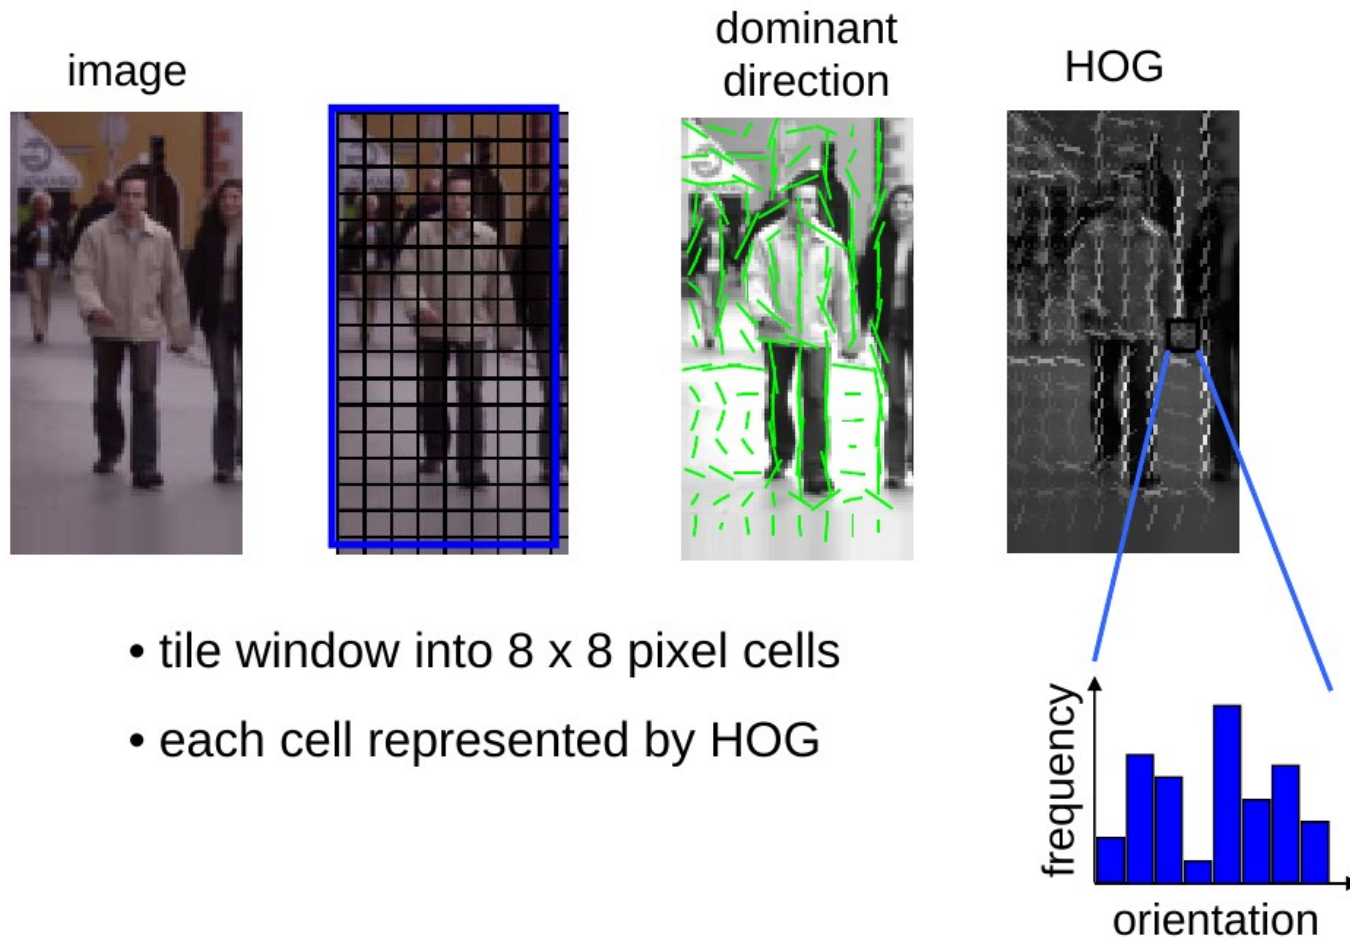
- Negative data – 1218 negative window examples (initially)



(Dalal & Triggs, 2005)

Exemplo de Aplicação





Feature: histogram of oriented gradients (HOG)



Feature vector dimension = 16×8 (for tiling) $\times 8$ (orientations) = 1024

(Dalal & Triggs, 2005)

Exemplo de Aplicação



(Dalal & Triggs, 2005)

Exemplo de Aplicação

Algorithm

Training (Learning)

- Represent each example window by a HOG feature vector



$\mathbf{x}_i \in \mathbb{R}^d$, with $d = 1024$

- Train a SVM classifier

Testing (Detection)

- Sliding window classifier

$$f(x) = \mathbf{w}^\top \mathbf{x} + b$$

(Dalal & Triggs, 2005)

Exemplo de Aplicação


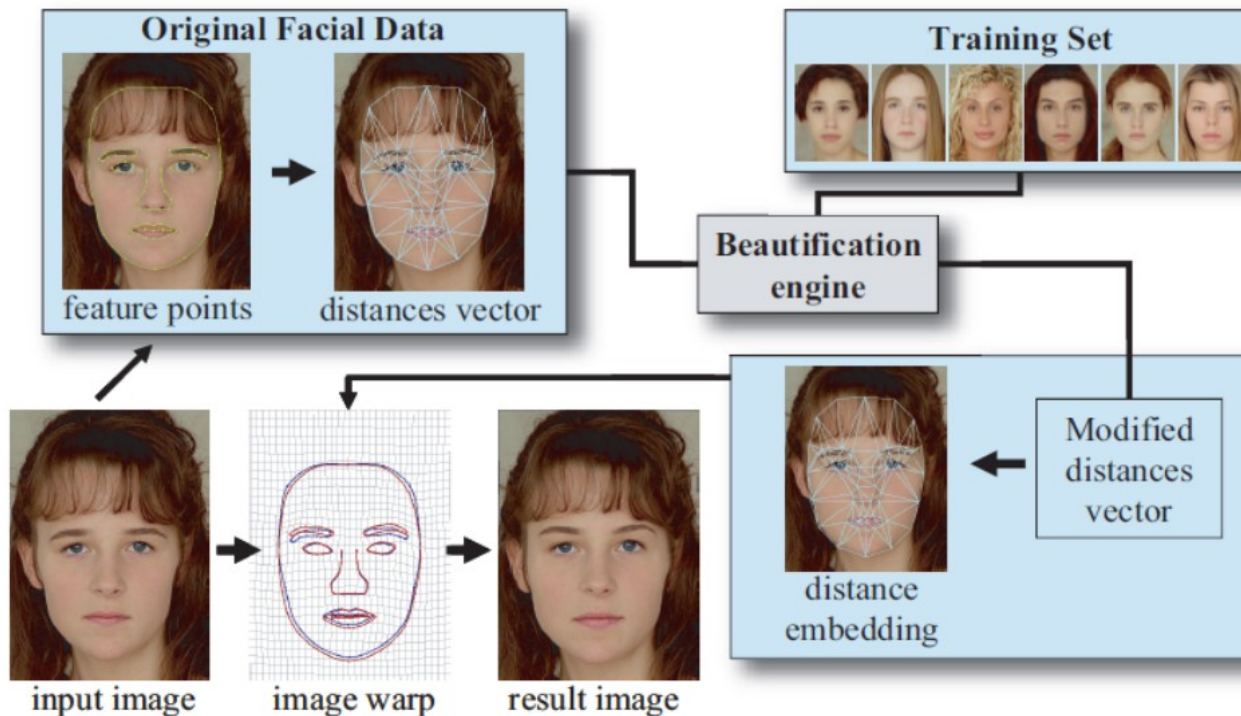


Dalal and Triggs, CVPR 2005

Exemplo de Aplicação

Application: Automatic Photo Retouching

[Leyvand et al., 2008]



Sugestão de Leitura

- Ler o Capítulo 9 do livro “*James, Witten, Hastie & Tibshirani, Introduction to Statistical Learning with applications in R, Springer, 2017.*”
- Capítulo 19 do livro do Russell & Norvig, *Artificial Intelligence: a modern approach*, 4th ed., Pearson, 2020.

Referências Bibliográficas

- Alpaydin, E. *Introduction to Machine Learning*. MIT Press, 2010.
- Bishop, C. *Pattern Recognition and Machine Learning*. Springer, 2006.
- James, G.; Witten, D.; Hastie, T. & Tibshirani, R. *An Introduction to Statistical Learning with applications in R*, Springer, 2017.
- Mitchell, T. *Machine Learning*. McGraw Hill, 1997.